

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO
TRIÂNGULO MINEIRO

ARTHUR BORGES INOCENCIO
FELIPE GABRIEL DOS SANTOS DORNELAS
PEDRI AUGUSTO DA SILVA ALEXANDRE

AGRUPAMENTO DE DADOS E INTELIGÊNCIA COMPUTACIONAL:
Recomendação educacional e predição de desempenho acadêmico

UBERLÂNDIA

2026

SUMÁRIO

1	INTRODUÇÃO	3
1.1	OBJETIVOS	3
2	INTEGRANTES E PAPÉIS EXERCIDOS	4
2.1	DADOS, PIPELINE E INTEGRAÇÃO	4
2.2	AGRUPAMENTO DE DADOS	4
2.3	INTELIGÊNCIA COMPUTACIONAL E DECISÃO	5
3	CENÁRIO ATRIBUÍDO	6
3.1	CENÁRIO ATRIBUÍDO E DESCRIÇÃO DO PROBLEMA	6
3.2	JUSTIFICATIVA EDUCACIONAL	6
4	BASE DE DADOS	7
5	AGRUPAMENTOS DE DADOS	9
5.1	ANÁLISE EXPLORATÓRIA	9
5.2	PRÉ-PROCESSAMENTO	9
5.3	ALGORITMOS DE AGRUPAMENTO UTILIZADOS	10
5.4	INTERPRETAÇÃO DOS GRUPOS	15
6	INTELIGÊNCIA COMPUTACIONAL	17
6.1	TÉCNICA UTILIZADA	17
6.2	CONSTRUÇÃO DA ÁRVORE DE DECISÃO	18
6.3	RESULTADOS DOS TESTES EM DIFERENTES CENÁRIOS	18
6.3.1	<i>Cenário 1</i>	18
6.3.2	<i>Cenário 2</i>	20
6.3.3	<i>Cenário 3</i>	21
6.3.4	<i>Cenário 4</i>	22
6.3.5	<i>Cenário 5</i>	24
7	CONCLUSÃO	26
8	REFERÊNCIAS	27

1 INTRODUÇÃO

Este é o relatório do trabalho final das disciplinas de Agrupamento de dados e Inteligência computacional. Disciplinas estas ministradas respectivamente pelos professores Gustavo Prado Oliveira e Clarimundo Machado Moraes Junior.

1.1 Objetivos

O objetivo da atividade é colocar em prática o conhecimento adquirido em ambas as disciplinas. Na parte de agrupamento de dados, conseguir realizar o tratamento e organização dos dados de forma a deixá-los favoráveis para boa análise e compreensão. Além de conseguir reconhecer, por meio das técnicas e ferramentas aprendidas, padrões e agrupamentos que nos devolvem cenários a serem analisados.

Acerca da disciplina de inteligência computacional, o objetivo é utilizar as técnicas aprendidas para reproduzir uma inteligência artificial que fosse capaz de prever resultados a partir dos dados, tendo assim o problema de regressão a ser resolvido.

2 INTEGRANTES E PAPÉIS EXERCIDOS

2.1 Dados, pipeline e integração

O Arthur ficou responsável por esta parte inicial do projeto, que foi feita assim que recebemos a base.

Para este papel, o aluno tinha que carregar a base de dados e documentar sua origem, realizar a análise exploratória inicial, tratar valores ausentes, duplicidades e inconsistências, transformar as variáveis categóricas e preparar os atributos numéricos e organizar o pipeline de dados.

Todo esse processo seria de extrema importância para as próximas etapas, pois envolve todo o reconhecimento e tratamento inicial da base recebida. É aqui que reconheceríamos o que nossa base está nos entregando.

2.2 Agrupamento de dados

O Felipe ficou responsável por realizar o agrupamento de dados.

Nesta etapa, o aluno deveria escolher os atributos para clusterização, justificar as medidas de distância ou similaridade, aplicar e testar algoritmos de agrupamentos diferentes, avaliar e comparar os clusters, interpretar perfis encontrados, gerar a saída que será usada na inteligência computacional.

Esta etapa também é importante pois aqui veríamos o que os dados podem nos dizer. Aplicando as ferramentas aprendidas em aula, conseguiríamos chegar em diferentes agrupamentos e definir qual seria o melhor para ser utilizado em nossa base.

2.3 Inteligência computacional e decisão

O Pedro ficou responsável por esta parte da atividade.

Aqui, o aluno deveria escolher a técnica de inteligência computacional que seria melhor utilizada para o problema, definir a tarefa final, construir e avaliar o modelo inteligente, comparar solução com e sem clusters, demonstrar a utilidade prática do produto final.

Por fim, aqui conseguiríamos chegar no objetivo final de nosso problema, onde unindo o agrupamento bem feito de dados e a inteligência computacional poderíamos não somente avaliar nossa base e agrupá-la por dados em comum, mas prever, recomendar, otimizar, classificar ou decidir.

3 CENÁRIO ATRIBUÍDO

3.1 Cenário atribuído e descrição do problema

O cenário que nos foi atribuído foi de recomendação educacional e predição de desempenho acadêmico.

Aqui, nosso problema era: Instituições de ensino que desejam identificar perfis de estudantes, prever risco acadêmico e recomendar ações pedagógicas personalizadas. Fazendo isso, seria possível encontrar um aluno que poderia ter possíveis problemas futuros e agir para evitá-los.

Utilizamos a base Student Performance - UCI Machine Learning Repository, que é sobre desempenho de estudantes de duas escolas portuguesas, com atributos demográficos, sociais e escolares e notas em matemática e português.

3.2 Justificativa educacional

Um modelo desse seria interessante principalmente no âmbito educacional. Utilizando-o poderíamos prever estudantes com possível risco escolar de reprovação, evasão ou desistência e planejar ações pedagógicas para evitar essas situações antes que elas de fato ocorram.

Com o modelo treinado não ficaríamos limitados apenas aos estudantes já cadastrados na escola, inclusive funcionaria melhor com alunos que entrariam posteriormente na instituição, pois o algoritmo já treinou com toda a base de dados anterior e conseguiria prever possíveis riscos dos novos estudantes.

4 BASE DE DADOS

A base é sobre o desempenho de estudantes de duas escolas portuguesas, com atributos demográficos, sociais, escolares e notas em Matemática e Português.

Possui os seguintes atributos:

1. school – escola do estudante (binário: "GP" - Gabriel Pereira ou "MS" - Mousinho da Silveira)
2. sex – sexo do estudante (binário: "F" - feminino ou "M" - masculino)
3. age – idade do estudante (numérico: de 15 a 22)
4. address – tipo de endereço residencial (binário: "U" - urbano ou "R" - rural)
5. famsize – tamanho da família (binário: "LE3" - menor ou igual a 3 ou "GT3" - maior que 3)
6. Pstatus – estado de coabitação dos pais (binário: "T" - juntos ou "A" - separados)
7. Medu – escolaridade da mãe (numérico: 0 - nenhuma, 1 - ensino primário (4ª série), 2 – 5ª a 9ª série, 3 – ensino secundário ou 4 – ensino superior)
8. Fedu – escolaridade do pai (numérico: 0 - nenhuma, 1 - ensino primário (4ª série), 2 – 5ª a 9ª série, 3 – ensino secundário ou 4 – ensino superior)
9. Mjob – profissão da mãe (nominal: "teacher" - professora, "health" - área da saúde, "services" - serviços civis, "at_home" - dona de casa ou "other" - outros)
10. Fjob – profissão do pai (nominal: "teacher" - professor, "health" - área da saúde, "services" - serviços civis, "at_home" - em casa ou "other" - outros)
11. reason – motivo para escolher esta escola (nominal: perto de "home" - casa, "reputation" - reputação, "course" - preferência pelo curso ou "other" - outros)
12. guardian – responsável pelo estudante (nominal: "mother" - mãe, "father" - pai ou "other" - outro)
13. traveltime – tempo de deslocamento casa-escola (numérico: 1 - <15 min., 2 - 15 a 30 min., 3 - 30 min. a 1 hora ou 4 - >1 hora)

14. studytime – tempo semanal de estudo (numérico: 1 - <2 horas, 2 - 2 a 5 horas, 3 - 5 a 10 horas ou 4 - >10 horas)
15. failures – número de reprovações anteriores (numérico: n se $1 \leq n < 3$, caso contrário 4)
16. schoolsup – apoio educacional extra (binário: sim ou não)
17. famsup – apoio educacional da família (binário: sim ou não)
18. paid – aulas extras pagas na disciplina (Matemática ou Português) (binário: sim ou não)
19. activities – atividades extracurriculares (binário: sim ou não)
20. nursery – frequentou pré-escola (binário: sim ou não)
21. higher – desejo de cursar ensino superior (binário: sim ou não)
22. internet – acesso à internet em casa (binário: sim ou não)
23. romantic – em relacionamento amoroso (binário: sim ou não)
24. famrel – qualidade das relações familiares (numérico: de 1 - muito ruim a 5 - excelente)
25. freetime – tempo livre após a escola (numérico: de 1 - muito baixo a 5 - muito alto)
26. goout – sair com amigos (numérico: de 1 - muito baixo a 5 - muito alto)
27. Dalc – consumo de álcool em dias de semana (numérico: de 1 - muito baixo a 5 - muito alto)
28. Walc – consumo de álcool nos finais de semana (numérico: de 1 - muito baixo a 5 - muito alto)
29. health – estado atual de saúde (numérico: de 1 - muito ruim a 5 - muito bom)
30. absences – número de faltas escolares (numérico: de 0 a 93)
31. G1 – nota do primeiro período (numérico: de 0 a 20)
32. G2 – nota do segundo período (numérico: de 0 a 20)
33. G3 – nota final (numérico: de 0 a 20, variável alvo)

5 AGRUPAMENTOS DE DADOS

5.1 Análise exploratória

Iniciamos a análise observando os atributos da nossa base, separando-os por atributos nominais, ordinais e intervalares. Observamos a base utilizada possui muitos atributos socioeconômicos, o que poderá nos auxiliar quando fizermos a divisão em clusters. Alguns exemplos são: famsup, activities, goout e health.

Além desses, serão utilizados os atributos comuns para análise de desempenho acadêmico, como notas, faltas, repetições e tempo de estudo.

5.2 Pré-processamento

Antes de começar a trabalhar com a base de dados para buscar resultados é necessário realizar o seu pré-processamento. Isso significa identificar os tipos de atributos, verificar a existência de valores ausentes, existência de registros duplicados, possíveis outliers existentes.

As verificações foram feitas da seguinte forma:

Verificação	Código em python
Valores ausentes	<code>ausentes = df.isna().sum().sort_values(ascending=False)</code>
Valores duplicados	<code>df.duplicated().sum()</code>

Após executar os códigos e verificar, não foi apresentado nenhum registro ausente ou valor duplicado.


Logo após, realizamos a verificação inicial da possível existência de outliers, utilizando um método estatístico chamado IQR (Interquartile Range). Esse método


separa os dados em quartis e identifica valores muito diferentes nesses quartis, definindo o limite inferior e o limite superior, sendo um bom método para análise inicial de outliers.

Após isso, realizamos a separação de atributos binários e nominais, que foram organizados da seguinte forma: Binários – school, sex, address, famsize, Pstatus, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic; Nominais – Mjob, Fjob, reason, guardian. Com essas transformações fica mais fácil utilizar as informações para um futuro agrupamento.

5.3 Algoritmos de agrupamento utilizados

Após o tratamento inicial dos dados, decidimos realizar a padronização dos dados pois é mais recomendado para modelos de regressão. E, após uma visualização gráfica, decidimos por utilizar a padronização, pois os dados ficavam melhor representados.





Pela representação é possível observar que, padronizando os dados ao invés de normalizá-los fica uma melhor observação e melhor divisão em clusters.


Escolhido a forma de reescalar estes dados, precisávamos escolher um algoritmo de clusterização. Optamos por inicialmente observar como o k-means se comportava. Utilizamos a medida de distância euclidiana, que é coerente para ser utilizada com o algoritmo. O motivo de escolha do k-means como o algoritmo inicial se deve pela sua facilidade na interpretação, eficiência, permite testar diferentes valores de k, gera centroides que podem ser analisados com perfis médios.



Uma limitação do k-means é o fato de ter que escolher em quantos k os dados serão divididos. Essa escolha não deve apenas ser feita aleatoriamente, mas deve seguir alguns parâmetros e testes de medida.

Testamos o valor de k entre 2 e 7, realizando algumas medidas para descobrir qual seria a melhor opção:

- **SSE** (Sum of Square Errors) – Mede a soma dos erros quadrados, medindo a diferença dos dados reais e os valores previstos pelo modelo. Quanto menor, melhor.

- **Silhouette score/inertia** – Mede o quão parecido um dado está com o seu próprio grupo em comparação a outros grupos. Mede a coesão (proximidade dos pontos dentro do mesmo grupo) e separação (distâncias entre os grupos diferentes). Quanto mais próximo de 1, melhor.
- **Davies-Bouldin** – Ele avalia o quão compactos são os grupos e o quão bem separados eles estão uns dos outros. Mede duas características, sendo elas a dispersão interna (a distância média entre os pontos de um grupo e o seu centroide) e a separação entre clusters (a distância entre os centroides de diferentes grupos).
- **Calinski-Harabasz** – Da mesma forma que os outros, mede a dispersão entre os clusters e a dispersão dentro deles. Um bom agrupamento significa que um cluster deve ser compacto e bem separado dos outros clusters.






	k	sse_iner cia	silhoue tte	davies_bou ldin	calinski_hara basz	tamanho_menor_c luster	tamanhos_clu sters
0	2	7415.772 6	0.1456	2.4917	89.0985	207	{0: 442, 1: 207}
1	3	6821.185 5	0.1547	2.2058	76.5128	66	{0: 384, 1: 199, 2: 66}
2	4	6371.407 1	0.1056	2.3295	69.7024	66	{0: 66, 1: 158, 2: 174, 3: 251}
3	5	5991.653 3	0.1116	2.1998	65.7082	57	{0: 63, 1: 57, 2: 195, 3: 218, 4: 116}
4	6	5703.498 0	0.1062	2.1133	61.6338	50	{0: 179, 1: 113, 2: 131, 3: 113, 4: 50, 5: 63}

Após realizar essas medições, automatizamos o processo de escolha, onde o nosso algoritmo escolhe o k com base no maior silhouette. Dessa forma, a quantidade de k escolhido foi igual a três. Os clusters ficaram divididos com a seguinte quantidade de exemplares em cada:

Cluster	Quantidade
0	384
1	199
2	66

Fizemos um resumo interpretável dos clusters, nos mostrando as médias da nota G1, como também sua mediana, a média do tempo de estudos, média de reprovações, mediana de faltas, média de faltas, percentual de apoio escolar, percentual de apoio familiar, percentual de atividades extracurriculares, média de relação familiar, média de tempo livre, média de saídas com os amigos, média de consumo de álcool no meio da semana, média do consumo de álcool no final de semana, média de saúde.

Para visualização dos clusters, utilizamos o PCA, pois foram utilizados 13 atributos e precisamos criar uma representação disso em 2D. O PCA funciona justamente para fazer essa adaptação.



5.4 Interpretação dos grupos

Para colocar em forma legível e interpretar de forma descritiva os clusters, decidimos montar uma tabela dando um nome descritivo aos clusters, além de destacar quais são suas principais características e propor uma intervenção pedagógica quando possível. Isso é importante pois, após a análise, é como uma exposição interpretativa de todas as descobertas.

Cluster	Características predominantes	Nome proposto	Intervenção pedagógica sugerida	Limitações da interpretação
0	Melhor desempenho	Alunos de alto desempenho	Mais apoio escolar	N/A

1	Muitas faltas	Alunos com muitas faltas	Entender motivos das faltas	N/A
2	Maior apoio escolar	Alunos com maior apoio escolar	N/A	Cluster com poucos alunos, características parecidas com o cluster 0.

6 INTELIGÊNCIA COMPUTACIONAL

6.1 Técnica utilizada

Em Inteligência Computacional estudamos três principais técnicas: RNA, AG e Árvore de decisão. O AG (Algoritmo genético) é utilizado para busca e otimização, neste caso, não sendo uma boa solução para o nosso problema. O RNA (Redes Neurais Artificiais) pode ser utilizado para reconhecimento de padrões, o que também não era exatamente o que estávamos procurando.

Dessa forma, optamos por utilizar a Árvore de decisão, que pode facilmente resolver problemas de regressão e predição, que é o que de fato queremos fazer, pois o nosso objetivo é, utilizando os atributos escolhidos, tanto escolares quanto socioeconômicos, de alguma forma prever qual será a nota do estudante no próximo período, ou sua nota final, e assim predizer um possível resultado negativo, permitindo uma ação para evitar essa resolução.

No Python já existem bibliotecas que auxiliam na construção do código de forma mais eficiente. Para construção foram utilizadas as bibliotecas da sklearn:

- `train_test_split` – utilizada para separar os dados que vão treinar e testar o algoritmo;
- `plot_tree` – utilizada para desenhar as árvores de decisões;
- `mean_absolute_error` – medir o erro médio dos resultados;
- `mean_squared_error` – medir o erro quadrático dos resultados.

A diferença entre os dois métodos de medir os erros é que o mean squared error (erro quadrático médio) é mais sensível a erros grandes, ou seja, se houver um erro que diferencia muito o resultado real do resultado previsto, ele consegue identificar de forma mais fácil que o mean absolute error (erro médio absoluto).

Para a definição do plano cartesiano, no eixo X foram utilizados os mesmos atributos que já foram anteriormente utilizados na modelagem dos dados e para o eixo

Y o atributo G2, que é o atributo que queremos prever para os estudantes de teste e novos estudantes.

6.2 Construção da Árvore de Decisão

Para o treinamento do algoritmo foram utilizados 75% dos dados, enquanto os outros 25% serão utilizados para testes.

Inicialmente, foi utilizado uma profundidade de 5 níveis para a árvore. Foi escolhido este valor pois, inicialmente, é um bom teste. Se deixássemos profundidade 1, por exemplo, seria uma árvore muito rasa, impedindo identificar melhores padrões, enquanto valores mais altos fazem com que ela se ajuste demais ao conjunto de treinamento, provocando um overfitting, que é a memorização dos dados.

Definimos o estado de aleatoriedade como Random, para que fosse 100% aleatório o algoritmo, porém, dessa forma, os resultados não poderiam ser reproduzíveis. Podemos definir um número para conseguir reproduzir os resultados.

6.3 Resultados dos testes em diferentes cenários

6.3.1 Cenário 1

Atributos eixo X: G1, studytime, failures, absences_log1p, schoolsup, famsup, activities, famrel, freetime, goout, Dalc, Walc, health.

Atributo eixo Y: G2.

Porcentagem de dados de treino: 75% (random_state=RANDOM_STATE)

Profundidade da árvore: 5

Aleatoriedade da árvore: RANDOM_STATE


Resultados Mean Absolute Error e Root Mean Squared Error:

MAE	RMSE
1.13	1.71

Amostra das previsões:

Aluno	G2 Real	G2 Predito
636	18	17.200
220	11	11.210
594	18	18.200
429	11	10.812
72	11	13.303

Árvore de Decisão para previsão de G2



6.3.2 Cenário 2

Atributos eixo X: G1, studytime, failures, absences_log1p, schoolsup, famsup, activities, famrel, freetime, goout, Dalc, Walc, health.

Atributo eixo Y: G2.

Porcentagem de dados de treino: 75% (random_state=RANDOM_STATE)

Profundidade da árvore: 7

Aleatoriedade da árvore: 42

Resultados Mean Absolute Error e Root Mean Squared Error:

MAE	RMSE
1.13	1.71

Amostra das previsões:

Aluno	G2 Real	G2 Predito
636	18	18.000
220	11	11.230
594	18	19.000
429	11	11.555
72	11	12.375

Decision tree visualization for the 'goout' variable. The root node splits on 'G1 <= 11.5'. The 'True' branch leads to a node splitting on 'G1 <= 8.5', which further splits into 'famrel <= 2.5' and 'G1 <= 10.5'. The 'False' branch leads to a node splitting on 'G1 <= 13.5', which further splits into 'G1 <= 12.5' and 'G1 <= 15.5'. Each of these branches continues to split based on various features like 'goout', 'health', 'studytime', 'absences_log1p', 'failures', and 'G1' again, eventually leading to leaf nodes with predicted values and sample sizes.

Atributos eixo X: G1, studytime, failures, absences_log1p, schoolsup, famsup, activities, famrel, freetime, goout, Dalc, Walc, health.

Porcentagem de dados de treino: 75% (random_state=RANDOM_STATE)


Aleatoriedade da árvore: 42

MAE	RMSE
1.28	1.86

Amostra das previsões:

Aluno	G2 Real	G2 Predito
636	18	17.200
220	11	11.210
594	18	18.200
429	11	10.812
72	11	13.303

Árvore de Decisão para previsão de G2



6.3.4 Cenário 4

Atributos eixo X: G1, G2, studytime, failures, absences_log1p, schoolsup, famsup, activities, famrel, freetime, goout, Dalc, Walc, health.

Atributo eixo Y: G3.

Porcentagem de dados de treino: 75% (random_state=RANDOM_STATE)

Profundidade da árvore: 5

Aleatoriedade da árvore: 42


Resultados Mean Absolute Error e Root Mean Squared Error:

MAE	RMSE
0.77	1.12

Amostra das previsões:

Aluno	G3 Real	G3 Predito
636	19	18.333
220	12	11.365
594	18	17.157
429	11	11.365
72	11	11.365

Árvore de Decisão para previsão de G2



6.3.5 Cenário 5

Atributos eixo X: G1, G2, studytime, failures, absences_log1p, schoolsup, famsup, activities, famrel, freetime, goout, Dalc, Walc, health.

Atributo eixo Y: G3.

Porcentagem de dados de treino: 75% (random_state=RANDOM_STATE)

Profundidade da árvore: 7

Aleatoriedade da árvore: 42


Resultados Mean Absolute Error e Root Mean Squared Error:

MAE	RMSE
0.78	1.20

Amostra das previsões:

Aluno	G3 Real	G3 Predito
636	19	18.000
220	12	11.151
594	18	17.000
429	11	11.151
72	11	11.151

Árvore de Decisão para previsão de G2



7 CONCLUSÃO

Ao final do trabalho concluímos que podemos unir a análise de dados para organizar, tratar e agrupar os dados unido à inteligência computacional, para prever, otimizar e organizar resultados.

Com nosso trabalho foi possível analisar de forma completa uma base de dados de estudantes de duas escolas portuguesas, matriculados no curso de português, observando suas características não somente acadêmicas, mas socioeconômicas, tentando inicialmente separá-los em grupos, com o objetivo de tratar esses estudantes de forma personalizada em sua jornada escolar.

Além disso, utilizamos a inteligência computacional para tentar prever as futuras notas desses estudantes, identificando o problema antes de acontecer, permitindo que intervenções pedagógicas distintas sejam tomadas nos diferentes perfis de alunos, evitando reprovações ou maus resultados finais.

Diferentes formas de utilizar os algoritmos também geram resultados diferentes, o que nos leva a concluir que é necessário realizar testes e análises para definir um melhor resultado final adequado ao problema a ser resolvido.

Chegamos a um bom resultado de predição final, tendo erros médios absolutos menores que 1. Isso se deve à boa organização inicial dos dados e melhor otimização do algoritmo de árvore de decisão.

8 REFERÊNCIAS

DATA CAMP. **Normalization vs. Standardization: How to Know the Difference.** [S. l.], 15 out. 2024. Disponível em: <https://www.datacamp.com/pt/tutorial/normalization-vs-standardization>. Acesso em: 29 jun. 2026.

KALIMARA. **Métricas de Agrupamento: Coeficiente de Silhueta, Índice de Davies-Bouldin e Índice de Calinski-Harabasz.** Medium, 6 abr. 2023. Disponível em: <https://medium.com/@kalimarapeleteiro/m%C3%A9tricas-de-agrupamento-coeficiente-de-silhueta-%C3%ADndice-de-davies-bouldin-e-%C3%ADndice-de-9462b87ce676>. Acesso em: 29 jun. 2026.